

Introdução a Regras de Associação

Autores: Andrey Mota de Oliveira
Claudio dos Santos Junior
Gabriel da Silva e Silva
Louise de Souza Santino

Agenda

O objetivo dessa apresentação é demonstrar o desenvolvimento de um sistema de recomendação utilizando o algoritmo FP-Growth para regras de associação, aplicado no dataset de transações de varejo.

1. Contextualização:

Objetivo, problema e aplicação do que foi feito baseado no dataset.

2. Algoritmo FP-Growth:

Apresentação do algoritmo, suas características, vantagens e desvantagens.

3. Regra de Associação:

Definição de antecedente, consequente, e exemplo prático.

4. Métricas de Avaliação:

Suporte, Confiança e Lift – fórmulas, cálculos e interpretações.

5. Pré-processamento dos Dados:

Limpeza, padronização e transformação das transações.

6. Resultados Obtidos:

Principais regras encontradas, análises e insights para o negócio.

7. Considerações Finais e Conclusão:

Aprendizados, limitações e possibilidades futuras

Contextualização

- A Dendê Softhouse é uma empresa focada em soluções digitais e análise de dados, responsável pelo aplicativo Dendê Eventos
- Saneamento e análise exploratória de dados brutos com Python, incluindo tratamento de inconsistências, valores ausentes e normalização de escalas.
- Transição para **NumPy e Pandas**, permitindo maior performance e escalabilidade no processamento.
- Nessa etapa usamos do **FP-Growth** para identificar padrões de consumo e viabilizar venda casada no vestuário.
- Transformação de transações em **regras de associação** para criação de combos e recomendações.



Algoritmo de Regra de Associação



Consiste em identificar padrões frequentes dentro de um conjunto de dados para descobrir relações entre itens.

- Utilizado para análise de cesta de pedidos (venda casada), segmentação de clientes e detecção de fraudes.
- Tendo como objetivo transformar transações brutas em regras de associação para criar combos e recomendações personalizadas.

FP Growth - Características

FP Growth	
Vantagens	Desvantagens
Processamento rápido	Lógica recursiva
Compressão dos dados	Alto uso de memória
Menos varreduras no banco de dados	Implementação complexa

Regra de Associação

Uma regra de associação é composta por um *antecedente* e um *consequente*, e ambos consistem em conjunto de itens.

Antecedente (X) → Consequente (Y)

- Antecedente: Item(s) encontrados na transação (“Se...”)
- Consequente: Item(s) previsto(s) pelo modelo (“Então...”)

Exemplo:

Se uma pessoa compra um Blazer

Então ela tem alta chance de comprar uma Gravata

Execução do Algoritmo na Regra

Análise e Ordenação de Itens

As transações são lidas e os itens são ordenados pela sua frequência global para otimizar a árvore.

Exemplo:

- T1**: Pão, Manteiga, Leite → **Ordenado**: Manteiga, Pão, Leite.
- T2**: Manteiga, Leite, Café → **Ordenado**: Manteiga, Leite, Café.
- T4**: Pão, Manteiga, Café → **Ordenado**: Manteiga, Pão, Café.
- T6**: Pão, Manteiga, Leite, Café → **Ordenado**: Manteiga, Pão, Leite, Café.

Construção da FP-Tree


Os dados são comprimidos em uma estrutura de árvore onde ramos compartilhados representam itens que frequentemente aparecem juntos.

Regra de Associação

Análise de Transações e Ordenação de Itens

Transações 🛒	Itens	Itens ordenados 📉
T1	Pão, Manteiga, Leite	Manteiga, Pão, Leite
T2	Manteiga, Leite, Café	Manteiga, Leite, Café
T3	Café, Adoçante	Café
T4	Pão, Manteiga, Café	Manteiga, Pão, Café
T5	Pão, Manteiga, Leite, Adoçante	Manteiga, Pão, Leite
T6	Pão, Manteiga, Leite, Café	Manteiga, Pão, Leite, Café

FP-TREE



Métrica de avaliação - Support

$$\text{Suporte}(X) = \frac{\sigma(X)}{N}$$

Objetivo: Só considerar padrões que aparecem com frequência mínima estabelecida.

X = Conjunto de itens (ex: {'short mauricinho', 'camisa regata'}).

$\sigma(X)$ = Número de transações que contêm o conjunto X (frequência absoluta).

N = Número total de transações no dataset.

Métrica de avaliação - Support



Exemplo:

Total de transações com "toalha lisa rosto" = 247

Total de transações válidas = 4990

$$\text{Suporte}(\text{toalha lisa rosto}) = \frac{247}{4990}$$

$$\text{Suporte}(\text{toalha lisa rosto}) = 0,0495 \text{ (ou 4,95\%)}$$

Métrica de avaliação - Confidence

$$\text{Confiança}(A \rightarrow B) = \frac{\text{Suporte}(A \cup B)}{\text{Suporte}(A)}$$

Objetivo: Medir a probabilidade de um cliente comprar um produto A, e por consequência comprar o produto B.

A = Antecedente (conjunto de itens à esquerda da regra)

B = Consequente (conjunto de itens à direita da regra)

$\sigma(A \cup B)$ = Transações que contêm A e B juntos

$\sigma(A)$ = Transações que contêm A (sozinho ou com outros)

Métrica de avaliação - Confidence

Exemplo:

A= Short Zafirinha

B= Regata Canelada

Transações com **A e B juntos** ($A \cup B$) = 52 compras.

Transações com **A** (apenas o Short) = 112 compras (sozinho ou com outros)

$$\text{Confiança} = \frac{52}{112}$$

$$\text{Confiança} = 0,4643 \text{ (ou } 46,43\%)$$

Métrica de avaliação - Lift

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confiança}(A \rightarrow B)}{\text{Suporte}(B)}$$

Objetivo: Ele responde se uma associação é **realmente relevante** ou se acontece apenas por acaso.

Lift = 1 – Neutro | Lift > 1 Recomendar | Lift < 1 - Evitar recomendação.

A = Antecedente (conjunto de itens à esquerda da regra).

B = Consequente (conjunto de itens à direita da regra).

Confiança(A→B) = Chance de B quando tem A.

Suporte(B) = Frequência de B no dataset.

Métrica de avaliação - Lift

Exemplo:

Suporte(B) = 0,0327

Confiança = 0,4643

A= Short Zafirinha

B= Regata Canelada

$$\text{Lift} = \frac{\text{Confiança}}{\text{Suporte}(B)} = \frac{0,4643}{0,0327} = 14,21$$

Interpretação: Quem compra o Short Zafirinha tem 14,21 vezes mais chance de comprar a Regata Canelada do que um cliente qualquer.

Pré-processamento de dados



- Na limpeza dos dados implementamos a função ***def limpar_item(item)***.

- Funções: padronizar itens pois isso evita que regras sejam criadas por diferenças de escrita.

EXEMPLO:

ENTRADA : "KIT MEIA LISA C PARES NO TAG PIMPOLHO UNISSEX A",
"MEIA LISA INVISIVEL - UNISSEX PIMPOLHO BRANCA".

SAÍDA : "kit meia lisa", "meia lisa invisível branca".

```
def limpar_item(item):  
  
    if not isinstance(item, str):  
        return ""  
  
    palavras_remove = [  
        'MIC', 'KIDS', 'BABY', 'FEM', 'MASC', 'UNISSEX', 'TAG', 'PARES',  
        'NO', 'COM', 'C', 'DE', 'A', 'E', 'O', 'DA', 'DO', 'DAS', 'DOS',  
        'PIMPOLHO', 'LA', 'MAYARA', 'LUZIANE', 'MICOL', 'DENGUINHO',  
        'MINASREY', 'SELENE', 'DOM', 'MATHEUS', 'HAOS', 'MARANDS',  
        'ITALICO', 'SERGIO', 'MODAS', 'DIFERENTE', 'MONTANHA', 'RUSSA'  
    ]  
  
    item = re.sub(r'[0-9]+', '', item)  
  
    for palavra in palavras_remove:  
        item = re.sub(rf'\b{palavra}\b', '', item, flags=re.IGNORECASE)  
  
    item = re.sub(r'^\w\s]', '', item)  
    item = re.sub(r'\s+', ' ', item).strip()  
  
    return item.lower()
```

Definição de Suporte e Confiança



Cálculo Suporte: $0,005 = \frac{\sigma(x)}{4990} \rightarrow \sigma(x) = 24 \text{ transações ou } 0,5\% \text{ do dataset}$

- A definição do Suporte foi baseada em 2 critérios, tamanho do dataset e encontro de combos relevantes.
- A Confiança $\geq 30\%$ é um percentual de corte, esse valor representa o equilíbrio ideal entre uniões relevantes e a qualidade estatística.

Exemplo:

transações short E camiseta bordada juntos: 54 transações
transações com short 104 transações.

$$\text{Suporte} = \frac{54}{104} = 0,5192 \text{ ou } 51\% \text{ (aprovado)}$$

Regras encontradas



- Foram encontradas **11 regras de associação** dentre eles destacamos:

short mauricinho → camisa regata - Suporte = 0,52% | Confiança = 44,07% | Lift = 23,64%

camisa manga longa infantil → mijão - Suporte = 0,48% | Confiança = 42,11% | Lift = 23,35%

camiseta bichinhos → short algodão - Suporte = 0,48% | Confiança = 33,33% | Lift = 15,99%

Exemplo de uso dos dados:

Organização do layout da loja colocando produtos complementares próximos.

Resultados



- Todos os testes passaram

Ran 12 tests in 0.008s

OK

Considerações finais

- Implementação manual do algoritmo FP-Growth exigiu cuidado redobrado na construção da FP-Tree e na mineração recursiva de padrões.
- Uso exclusivo de bibliotecas básicas (pandas e re) demonstrou ser suficiente para processar 4.990 transações.
- A experiência com implementação manual reforçou conceitos fundamentais de mineração de dados, como suporte, confiança, lift e a construção de estruturas de dados em árvore.
- É possível construir soluções robustas de regras de associação com Python puro, desde que haja planejamento adequado da estrutura de dados e dos parâmetros de mineração.

Referências

●SUNIGA, Abner Ferreira; SALES, Diogo. **Encontre padrões nos seus dados com Apriori e FP Growth**. Medium, 9 maio 2020. Disponível em: <https://medium.com/@abnersuniga7/encontre-padr%C3%B5es-nos-seus-dados-com-apriori-e-fp-growth-4a581ec1b22>. Acesso em: 10 maio 2026.

●BRASIL, Patrícia M. F.; SANTOS, Marilde T. P.; MARCACINI, Ricardo M. **Mineração de Padrões Frequentes em Dados de Transações: Uma Abordagem Prática com FP-Growth**. In: WORKSHOP DE TESES E DISSERTAÇÕES EM BANCO DE DADOS (WTDBD), 32., 2019, Rio de Janeiro. **Anais [...]**. Porto Alegre: SBC, 2019. p. 12-15. Disponível em: <https://sol.sbc.org.br/index.php/wtddb/article/view/8940>. Acesso em: 10 maio 2026